

# **Contagio de volatilidad financiera: Análisis mediante redes de cointegración y Network GARCH**

Alexander Chi Fernandez

diciembre 11, 2025

# Resumen

Este artículo examina el contagio de volatilidad entre los principales mercados financieros mediante un enfoque híbrido que integra redes de cointegración y el modelo Network GARCH. Con el fin de evaluar si la pandemia de Covid-19 alteró los mecanismos de transmisión del riesgo, se comparan dos periodos contrastantes: 2015–2019 y 2020–2024.

Los resultados revelan que, pese al incremento en la volatilidad global durante la pandemia, la transmisión de choques entre mercados no se fortaleció; por el contrario, los efectos de contagio observados en el primer periodo desaparecieron por completo en el segundo.

Este hallazgo indica que, incluso en contextos de elevada incertidumbre, la volatilidad no se propagó entre los mercados analizados, lo que aporta evidencia consistente de un entorno con niveles mínimos de contagio financiero a lo largo del horizonte estudiado.

## 1. Introducción

En un mundo cada vez más globalizado, las economías están profundamente interconectadas, lo que provoca que los acontecimientos en un mercado puedan influir en otros.

Este artículo analiza la dinámica con la que la volatilidad se transmite entre distintos mercados financieros, utilizando un enfoque híbrido que integra redes de cointegración con un modelo Network GARCH. Esta combinación permite identificar tanto las relaciones de largo plazo entre los mercados como los mecanismos a través de los cuales los choques de volatilidad se propagan dentro de la red financiera.

El término “contagio” fue introducido por primera vez en 1997, a raíz de la crisis monetaria de Tailandia, la cual se propagó rápidamente a otras economías de Asia oriental y, poste-

riormente, a Rusia y Brasil en un lapso de menos de dos meses. Su definición se entiende como la tendencia de una crisis a propagarse de un país a otros, generando efectos globales, [Claessens & Forbes \(2001\)](#).

En este sentido, el contagio suele asociarse con escenarios negativos, pues implica la transmisión de tensiones financieras que amplifican la inestabilidad. Sin embargo, en periodos de expansión económica también puede observarse una forma de “contagio positivo”, en el que el dinamismo de ciertos mercados se difunde hacia otros, generando un auge más generalizado. En cualquiera de sus manifestaciones, los contagios condicionan de manera importante las estrategias de gestión de portafolios, negociación, cobertura y diversificación, ya que modifican los patrones tradicionales de riesgo.

Antes de analizar la transmisión de volatilidad entre mercados, es fundamental revisar las principales métricas que históricamente se han utilizado para cuantificar el riesgo y la volatilidad.

En primer lugar, [Sharpe \(1964\)](#) define el riesgo sistemático como la pendiente de la regresión lineal entre el rendimiento de un activo  $i$  y el del portafolio del mercado  $m$  que en la práctica se suele representar por algún índice bursátil representativo.

Asimismo, [J.P. Morgan / Reuters \(1996\)](#) introdujo por primera vez la metodología VaR (Value at Risk), la cual es una métrica para medir el riesgo. El VaR se define como la pérdida máxima esperada de una cartera durante un horizonte temporal determinado, bajo un nivel de confianza específico.

Por otro lado, [Markowitz \(1952\)](#) presentó la idea sobre la representación del riesgo de una inversión por la varianza de los retornos, una medida estadística que mide la dispersión de una serie de datos sobre su media correspondiente, la cuál fue introducida después como

medida de volatilidad por [Black & Scholes \(1973\)](#) en el modelo Black-Scholes para la fijación de precios de las opciones europeas.

En conjunto, estas aportaciones sentaron las bases para la medición formal del riesgo y la volatilidad a través de la varianza y la desviación estándar de las variables financieras.

La idea de analizar cómo la volatilidad se transmite entre los mercados se aborda precisamente mediante el modelo Network GARCH, el cuál permite identificar cómo un aumento conjunto de la varianza dentro de una red financiera puede influir en otros mercados a través de la varianza condicional. Este proceso se describe con mayor detalle en la sección de metodología.

Como complemento, de acuerdo con [Rossi \(2013\)](#), la volatilidad es altamente sensible al flujo de información que influye en la formación de los precios. En otras palabras, está vinculada a la rapidez con la que surge nueva información relevante sobre la oferta y la demanda, pues es este proceso es el que determina el punto de equilibrio. Cuando las cotizaciones cambian, ya sea al alza o a la baja, la volatilidad puede aumentar o disminuir dependiendo de la magnitud de dichas variaciones en relación con su promedio.

Por ello, se utilizan redes de cointegración como complemento del modelo, ya que permiten capturar las relaciones de largo plazo entre las variables, reflejando un comportamiento común formado y explicado por información similar. Este proceso se detalla igualmente en la sección de metodología.

Con base en lo previamente mencionado, el presente análisis se orienta a estudiar cómo las volatilidades se contagian de manera directa y cuantificada dentro de un sistema global de mercados financieros representado por una red, tanto en contextos de baja como de alta incertidumbre.

De igual forma, es pertinente mencionar algunos otros enfoques existentes para el estudio del contagio financiero.

[Forbes & Rigobon \(2002\)](#) argumentan que un aumento en las varianzas puede elevar artificialmente la correlación entre mercados, generando interpretaciones erróneas sobre la existencia de contagio durante episodios de crisis. Los autores muestran que, una vez corregido este sesgo, en eventos históricos como la crisis asiática de 1997 y la devaluación mexicana de 1994 no se observa un incremento significativo en la correlación incondicional, sino más bien un patrón persistente de interdependencia entre mercados.

Siguiendo esta línea, otros estudios han explorado la transmisión de contagio financiero entre mercados específicos utilizando diferentes metodologías. Por ejemplo, [Rodríguez Benavides & Perrotini Hernández \(2021\)](#) analiza la interacción entre el mercado accionario de Estados Unidos y los principales mercados de América Latina durante el periodo 2002-2009. Mediante un modelo DCC GARCH para estimar correlaciones dinámicas condicionales de los rendimientos diarios, y un modelo de cambio de régimen Markoviano para capturar variaciones abruptas, los autores encuentran evidencia de contagio financiero desde Estados Unidos hacia los mercados latinoamericanos incluso antes de la quiebra de Lehman Brothers.

Por su parte, [Carriello \(2005\)](#) se centra en países emergentes latinoamericanos durante crisis financieras recientes, analizando spreads de bonos soberanos mediante el índice Emerging Markets Bond Index Plus (EMBI+) de JP Morgan, los retornos de los índices bursátiles MSCI y los flujos de capital hacia estos mercados. Sus resultados indican que, aunque se observan correlaciones temporales, la evidencia de contagio es débil y podría explicarse más por factores internos de política financiera compartidos entre países con características similares, que por una transmisión directa de choques externos.

Para concluir esta sección, es importante detallar la elección de los periodos a estudiar.

Con el fin de capturar las distintas dinámicas del contagio financiero en periodos de alta y baja volatilidad, este artículo compara dos etapas contrastantes: el periodo prepandemia (2015-2019) y el periodo pandémico y pospandémico (2020-2024), caracterizado por una elevada incertidumbre derivada de la propagación del Covid-19.

La hipótesis central es que el existe más contagio financiero durante el periodo pandémico y pospandémico que antes de la pandemia del Covid-19, esto reflejando que las crisis aumentan el contagio del riesgo entre los mercados.

La elección de estos dos periodos no es arbitraria. La razón principal proviene de observar que el VIX presenta comportamientos claramente distintos entre ambos. CBOE Volatility Index, conocido como VIX, mide la volatilidad implícita del S&P 500 para los siguientes 30 días. Cuando esta volatilidad implícita es alta, el nivel del VIX es alto y el rango de valores probables es amplio. Cuando la volatilidad implícita es baja, el nivel del VIX es bajo y el rango es reducido, [Indices \(2025\)](#).

A pesar de representar únicamente la volatilidad del S&P 500, el VIX funciona como un buen indicador general, ya que el mercado de capitales estadounidense —la Bolsa de Nueva York y el Nasdaq— es el que cuenta con mayor capitalización del mundo, por lo que resulta razonable tomarlo como referencia para evaluar la volatilidad global, [Monex \(2024\)](#).

El índice VIX, cuando se encuentra entre 0 y 15, suele reflejar optimismo y estabilidad en los mercados financieros. A medida que aumenta, indica un mayor nivel de incertidumbre, y cuando supera los 30 puntos, se asocia con turbulencia extrema y un alto grado de temor entre los inversionistas.

En la Figura 1 se aprecia un cambio estructural a partir de 2020, ya que el índice ha

mantenido niveles más elevados en comparación con los años previos.

La media del VIX entre 2015 y 2019 fue de 15.13, mientras que entre 2020 y 2024 aumentó a 21.42, lo que evidencia un incremento significativo en la volatilidad del mercado estadounidense.

Comparar ambos periodos permite, por lo tanto, identificar cómo un evento sistémico modificó los patrones de contagio financiero. Asimismo, facilita analizar si la transmisión de la volatilidad se intensifica en un entorno de crisis global respecto a un periodo de relativa normalidad económica, ofreciendo evidencia relevante para la gestión del riesgo y la formulación de políticas financieras.




Figura 1: VIX.

Nota: Elaboración propia con datos de Yahoo Finance.

## 2. Datos

Las variables utilizadas en el análisis corresponden a los principales índices bursátiles representativos de los mercados financieros más relevantes. En particular, se consideran 24 índices de referencia de Norteamérica, Sudamérica, Europa y Asia, además de algunos adicionales de otras regiones de interés.

En la tabla 1 se presenta el país y el ticker correspondiente de cada índice.

Los datos fueron obtenidos de Yahoo Finance, asegurando tanto la disponibilidad histórica como la consistencia de la información empleada en el análisis.

Tabla 1: Índices bursátiles considerados por país

País	Índice	País	Índice	País	Índice
Estados Unidos	$\wedge$ GSPC	España	$\wedge$ IBEX	Australia	$\wedge$ AXJO
México	$\wedge$ MXX	Italia	FTSEMIB.MI	Corea del Sur	$\wedge$ KS11
Canadá	$\wedge$ GSPTSE	Suiza	$\wedge$ SSMI	Taiwán	$\wedge$ TWII
Brasil	$\wedge$ BVSP	Rusia	IMOEX.ME	Indonesia	$\wedge$ JKSE
Argentina	$\wedge$ MERV	Japón	$\wedge$ N225	Singapur	$\wedge$ STI
Reino Unido	$\wedge$ FTSE	China	000001.SS	Nueva Zelanda	$\wedge$ NZ50
Alemania	$\wedge$ GDAXI	Hong Kong	$\wedge$ HSI	Israel	$\wedge$ TA125.TA
Francia	$\wedge$ FCHI	India	$\wedge$ NSEI	Arabia Saudita	$\wedge$ TASI.SR

La muestra de observaciones se divide en dos periodos: 2015–2019 y 2020–2024, con una duración de cinco años cada uno. El primer periodo cuenta con 583 observaciones, mientras que el segundo comprende 493 observaciones.



En la figura 2 se presenta una visualización de algunos índices seleccionados, con el propósito de mostrar el comportamiento histórico de las variables analizadas.

Particularmente, se observa que existen periodos en los que las series de tiempo tienden a comportarse de manera similar e incluso a compartir una misma tendencia temporal.

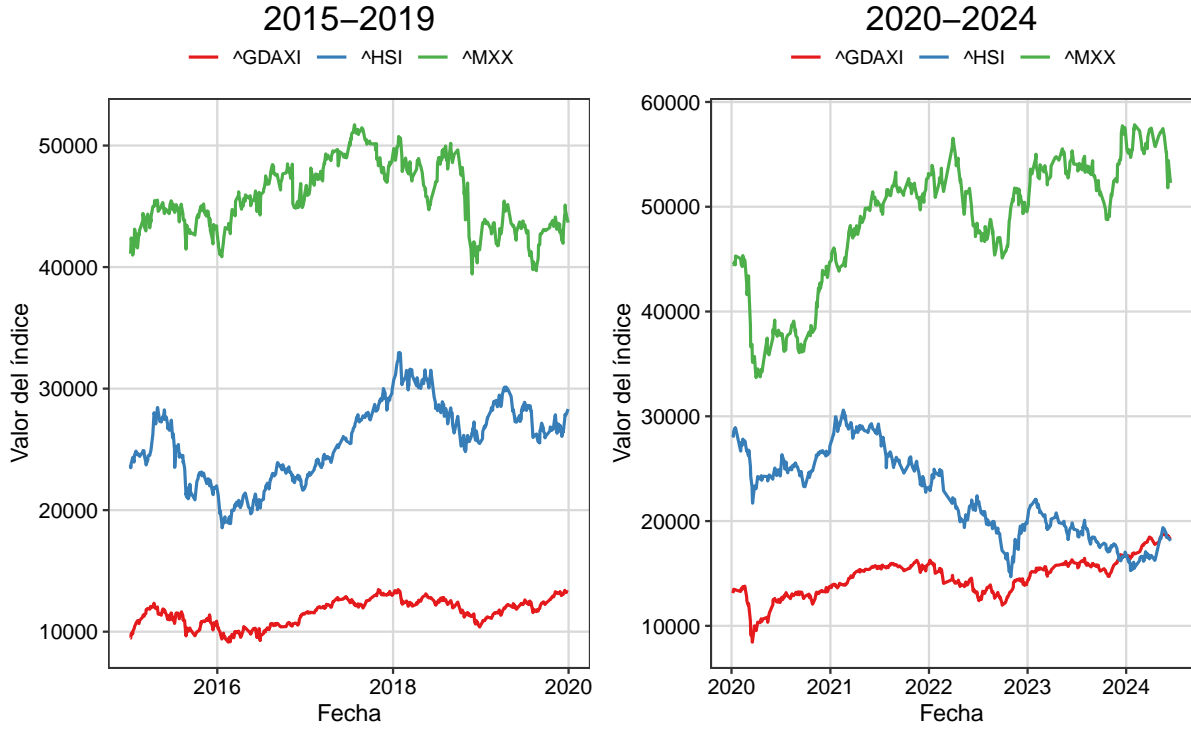


Figura 2: Series en niveles.

Nota: Elaboración propia con datos de Yahoo Finance.

Sus respectivos retornos logarítmicos en la figura 3, calculados de la siguiente manera:

$$\text{Retorno logarítmico} = \ln \left( \frac{V_t}{V_{t-1}} \right) \quad (1)$$

donde:

- $V_t$  es el valor del índice en el periodo actual.
- $V_{t-1}$  es el valor del índice en el periodo anterior.

En los retornos se observa que las variaciones difieren considerablemente entre ambos periodos. Basta con revisar el eje Y: en el panel correspondiente a 2015–2019, los valores fluctúan entre  $-0.10$  y  $0.05$ , mientras que en el periodo 2020–2024 alcanzan un rango más amplio, de  $-0.10$  a  $0.15$ .




Figura 3: Retornos diarios.

Nota: Elaboración propia con datos de Yahoo Finance.

En la figura 4 se presentan los retornos cuadráticos, que corresponden a los retornos logarítmicos elevados al cuadrado. Estos se utilizan como una aproximación de la varianza de los errores en un modelo con media condicional. Se observa que, al igual que en la gráfica de retornos, la escala del eje y es más amplia en el panel correspondiente a 2020–2024 que en el de 2015–2019. Esto refleja que, durante el periodo 2020–2024, la varianza y, en consecuencia, la volatilidad de las series es considerablemente mayor. En conjunto, esta

evidencia confirma un incremento significativo de la volatilidad en los distintos mercados financieros durante dicho periodo.




Figura 4: Retornos Cuadráticos.

Nota: Elaboración propia con datos de Yahoo Finance.

### 3. Metodología

El enfoque del presente artículo es cuantitativo y empírico, empleando modelo econométrico de la familia ARCH combinado con redes de cointegración.

Una de las herramientas principales para la modelación de volatilidad de las series de tiempo es el modelo ARCH (Autoregressive Conditional Heteroskedasticity, o Heterocedasticidad Condicional Autorregresiva en español) el cual fue propuesto por primera vez por [Engle \(1982\)](#) para modelar la inflación del Reino Unido.

La metodología empleada es el modelo Network GARCH, una extensión del modelo ARCH propuesta por [Zhou et al. \(2020\)](#) que consiste en modelar la varianza condicional de las series de tiempo de manera univariada, incorporando además relaciones entre las variables mediante una estructura de grafos. Esto permite analizar tanto las interdependencias como el contagio de volatilidad entre mercados.

La estructura de un modelo Network GARCH es la siguiente:

$$r_{i,t} = \mu_i + \sigma_{i,t}\epsilon_{i,t} \quad (2)$$

$$\sigma_{i,t}^2 = \omega_i + \alpha_i r_{i,t}^2 + \beta_i \sigma_{i,t-1}^2 + \lambda_i d_i^{-1} \sum_j a_{i,j} r_{j,t-1}^2 \quad (3)$$

donde:

- $r_{it}$  es el retorno de la variable  $i$  en el tiempo  $t$ .
- $\mu_i$  es la media de la variable  $i$ .
- $\epsilon_{it}$  es el choque aleatorio de la variable  $i$  en el tiempo  $t$ .
- $\sigma_{it}^2$  es la varianza condicional de la variable  $i$ .
- $\omega$  es una constante positiva que asegura varianza positiva.
- $\alpha$  es el coeficiente que mide el efecto de los choques pasados propios de un rezago.
- $\beta$  es el coeficiente que mide la persistencia de la volatilidad.
- $\lambda$  Es el parámetro que captura la influencia promedio de los choques provenientes de los vecinos en la red con un rezago.
- $d_i$  es el grado del nodo  $i$ , es decir, la suma de las conexiones de  $i$ .
- $a_{ij}$  es el elemento de la matriz de adyacencia  $A$ ; indica si el nodo  $i$  está conectado con el nodo  $j$ .

Para la construcción de la red, cada nodo representa un índice bursátil y solo se establece una arista entre dos nodos si existe una relación de cointegración por el método de Engle - Granger en sus respectivas series en niveles.

La red se establece por la matriz de adyacencia  $A$ . Dentro de la matriz  $A$  solo existen valores de 1 y 0 de manera simétrica para obtener la relación mencionada.

Esta estrategia busca incluir en el modelo únicamente aquellos índices que comparten una misma tendencia de largo plazo en las observaciones, ya que dicha coincidencia puede indicar que los mercados están siendo afectados por informaciones similar. En consecuencia, los choques de volatilidad generados en uno de ellos podrían influir en los demás.

De acuerdo a [Engle & Granger \(1987\)](#), la cointegración se puede definir como una relación de equilibrio a largo plazo entre variables no estacionarias. Aunque cada variable por si sola sea integrada, existe una combinación lineal de ellos que si estacionaria. Si los residuales de la regresión entre las variables son estacionarios entonces se estaría indicando la existencia de una relación de equilibrio estable entre ellas.

Para determinar la relación de cointegración entre las variables, se aplica la prueba de Dickey-Fuller Aumentada a los residuales de la regresión lineal entre ellas. Si dichos residuales resultan ser estacionarios al 95 % de confianza, entonces se reconoce que existe cointegración.

El procedimiento se realiza siguiendo un enfoque de lo general a lo particular: primero se estima la regresión ADF incluyendo los términos de tendencia y deriva. Posteriormente, se verifica si estos términos son estadísticamente significativos para evaluar la estacionariedad; en caso de no serlo, se van eliminando siguiendo la jerarquía: primero la tendencia y luego la deriva.

En el modelo definido en (3), para obtener la solución estacionaria se debe cumplir la condición:

$$\alpha + \beta + \lambda < 1 \quad (4)$$

Esta condición asegura que el modelo tenga una única solución estrictamente estacionaria y con momentos finitos. Cabe aclarar que dicha condición solo es válida cuando el número de nodos es fijo. Si el número de nodos crece (es decir, si la red aumenta su dimensión), el concepto mismo de estacionariedad se vuelve problemático y la condición deja de ser aplicable.

En el presente análisis, dado que se utilizan 24 variables, la condición de estacionariedad puede considerarse satisfecha sin inconvenientes.

La estimación de parámetros se lleva a cabo por cuasi-máxima verosimilitud (QMLE) bajo el supuesto de la distribución normal. Considerando la ecuación (3), la cuasi log-verosimilitud está dada por:

$$L(\theta) = \frac{1}{T} \sum_{t=1}^T \tilde{\ell}_t(\theta), \quad \tilde{\ell}_t(\theta) = \frac{1}{N} \sum_{i=1}^N \left\{ \log \tilde{\sigma}_{it}^2(\theta) + \frac{y_{it}^2}{\tilde{\sigma}_{it}^2(\theta)} \right\} \quad (5)$$

La varianza condicional aproximada  $\tilde{\sigma}_{it}^2(\theta)$  se define recursivamente como:

$$\tilde{\sigma}_{it}^2(\theta) = \omega + \alpha r_{i,t-1}^2 + \beta \tilde{\sigma}_{i,t-1}^2(\theta) + \lambda d_i^{-1} \sum_{j \neq i} a_{ij} r_{j,t-1}^2 \quad (6)$$

con la condición inicial  $\tilde{\sigma}_{i0}^2(\theta) = 0$ .

El estimador QMLE se define como:

$$\hat{\theta} = (\hat{\omega}, \hat{\alpha}, \hat{\lambda}, \hat{\beta})' = \arg \min_{\theta \in \Theta} \tilde{L}(\theta) \quad (7)$$

Para estudiar las propiedades asintóticas del estimador  $\hat{\theta}$ , se aproxima la secuencia  $\tilde{\sigma}_{it}^2(\theta)$  por una versión estacionaria  $\sigma_{it}^2(\theta)$ . Bajo los supuestos estándar de modelos GARCH como

i.i.d. en los errores, varianza unitaria, parámetros positivos y la condición  $\alpha + \lambda + \beta < 1$ — se tiene que:

$$\hat{\theta} \xrightarrow{\text{c.s.}} \theta_0 \quad \text{cuando } T \rightarrow \infty \quad (8)$$

es decir, el estimador es fuertemente consistente.

Además, si el cuarto momento de los errores es finito, la distribución asintótica viene dada por:

$$\sqrt{NT} (\hat{\theta} - \theta_0) \xrightarrow{d} N(0, (\kappa_4 - 1)\Sigma^{-1}) \quad (9)$$

donde  $\kappa_4 = \mathbb{E}(\varepsilon_{it}^4)$  y la matriz  $\Sigma$  depende de las derivadas de la varianza condicional respecto a los parámetros del modelo.

La matriz  $\Sigma$  se calcula como:

$$\Sigma = \frac{1}{N} \sum_{i=1}^N \mathbb{E} \left[ \frac{1}{\sigma_{it}^4(\theta_0)} \frac{\partial \sigma_{it}^2(\theta_0)}{\partial \theta} \frac{\partial \sigma_{it}^2(\theta_0)}{\partial \theta'} \right] \quad (10)$$

donde

$$\frac{\partial \sigma_{it}^2(\theta_0)}{\partial \theta} = \begin{pmatrix} 1 \\ r_{i,t-1}^2 \\ d_i^{-1} \sum_{j \neq i} a_{ij} r_{j,t-1}^2 \\ \sigma_{i,t-1}^2 \end{pmatrix} + \beta \frac{\partial \sigma_{i,t-1}^2(\theta_0)}{\partial \theta} \quad (11)$$

Finalmente, la matriz de adyacencia  $A$  participa directamente en el cálculo de estas derivadas, ya que determina cómo la volatilidad de cada variable se ve afectada por sus nodos vecinos en la red.

## 4. Resultados

En esta sección, se utiliza el modelo propuesto para analizar los mercados globales.

En la Figura 5 se muestra la red de cointegración correspondiente al Periodo 1 (2015–2019), mientras que en la Figura 6 se presenta la red asociada al Periodo 2 (2020–2024).

Antes de avanzar con el modelo Network GARCH, resulta útil revisar primero las redes y sus estructuras.




Figura 5: Red de cointegración 1.

Nota: Elaboración propia con datos de Yahoo Finance.

La densidad de las redes aumentó ligeramente de 0.5652 en la Figura 5 a 0.5688 en la Figura 6, lo cual indica un pequeño incremento en la cantidad de relaciones estables de largo plazo entre las series.

El efecto de la crisis pandémica no generó un aumento significativo en las relaciones de cointegración; es decir, la cantidad de mercados que comparten una misma tendencia no se vio afectada de manera relevante como consecuencia de la pandemia.



Este hallazgo resulta particularmente interesante, ya que desde la perspectiva de las redes de cointegración, los mercados no tendieron a moverse conjuntamente a raíz de una misma crisis.




Figura 6: Red de cointegración 2.

Nota: Elaboración propia con datos de Yahoo Finance.

En la Tabla 2 se presenta el grado por nodo de las redes. La comparación entre la red 1 y la red 2 muestra los cambios en las conexiones o tendencias compartidas entre los distintos mercados financieros.

Se observa que los mercados de Estados Unidos, Argentina, Alemania, Rusia, Japón y Taiwán perdieron conexiones, mientras que los mercados de España, Italia, China, Hong Kong y Nueva Zelanda ganaron grados.

Esto sugiere una dinámica cambiante en las tendencias financieras compartidas entre los

diferentes países.

De igual manera, esto modifica los vecinos de los índices dentro de la red en ambos periodos, lo que termina afectando los resultados del modelo Network GARCH.

Tabla 2: Grados por nodos de redes

Nodos	Grafo 1	Grafo 2	Diferencia	Nodos	Grafo 1	Grafo 2	Diferencia
$\hat{G}SPC$	18	14	-4	$\hat{N}225$	18	13	-5
$\hat{M}XX$	8	13	5	000001.SS	13	16	3
$\hat{G}SPTSE$	16	15	-1	$\hat{H}SI$	8	12	4
$\hat{B}VSP$	19	10	-9	$\hat{N}SEI$	16	12	-4
$\hat{M}ERV$	20	10	-10	$\hat{A}XJO$	17	20	3
$\hat{F}TSE$	16	17	1	$\hat{K}S11$	5	6	1
$\hat{G}DAXI$	15	12	-3	$\hat{T}WII$	14	9	-5
$\hat{F}CHI$	15	14	-1	$\hat{J}KSE$	13	11	-2
$\hat{I}BEX$	8	15	7	$\hat{S}TI$	15	19	4
FTSEMIB.MI	10	13	3	$\hat{N}Z50$	8	21	13
$\hat{S}SMI$	16	18	2	$\hat{T}A125.TA$	5	10	5
IMOEX.ME	11	3	-8	$\hat{T}ASL.SR$	8	11	3

Los resultado del modelo Network GACRH para el periodo de 2015-2019 se presenta en la tabla 3. En ella se muestran los índices bursátiles que reciben influencia de volatilidad por parte de sus vecinos dentro de la red, así como la magnitud de dichos efectos y sus significancia estadísticas, representada por el valor p.

Tabla 3: Resultado Network GARCH 2015-2019

índice Bursátiles	Lambda	P Value	Significativo
$\hat{\gamma}^{TWII}$	0.1607726	0.0005197	Sí
$\hat{\gamma}^{TA125.TA}$	0.0363219	0.0000083	Sí
$\hat{\gamma}^{GSPTSE}$	0.0232240	0.0021789	Sí

En la Tabla 3 se observa que, para el periodo 2015–2019, únicamente Taiwán, Israel y Canadá presentaban efectos estadísticamente significativos provenientes de sus países vecinos dentro de la red. Entre ellos, Taiwán registraba el impacto más elevado: Un aumento promedio en la varianza de sus vecinos en un periodo rezagado se asociaba con un incremento de 0.16 en su propia varianza en el momento  $t$ . Aunque este coeficiente es el más alto dentro del periodo, su magnitud sigue siendo extremadamente pequeña en términos económicos, lo que indica que los choques de volatilidad transmitidos a través de la red prácticamente no generaban perturbaciones relevantes en estos mercados. En conjunto, la presencia de tan solo tres países con efectos significativos y la baja magnitud de dichos impactos permiten concluir que, durante esta etapa de baja volatilidad global, el contagio financiero era mínimo.

En contraste, para el periodo 2020–2024 no se identificó ningún mercado con influencia estadísticamente significativa proveniente de sus vecinos. Este resultado es particularmente relevante, ya que sugiere que la pandemia no fortaleció los mecanismos de contagio financiero dentro de la red; por el contrario, estos efectos se diluyeron por completo. Mientras que en el primer periodo al menos tres mercados mostraban algún grado de transmisión de volatilidad, a partir de 2020 la influencia entre mercados cayó a cero.

A partir de estos resultados, se rechaza la hipótesis previamente planteada, la cual sugería que un entorno de mayor volatilidad como el observado durante la pandemia podría amplificar el contagio financiero dentro de la red. Si bien la densidad de la red de cointegración aumentó ligeramente durante el segundo periodo, este incremento no se tradujo en una mayor cantidad de mercados afectados por la volatilidad de sus vecinos. Por el contrario, la ausencia total de efectos significativos demuestra que la transmisión de choques se debilitó aún más. En suma, tanto antes como durante y después de la pandemia, los mercados permanecieron prácticamente aislados de los choques de volatilidad de sus contrapartes, lo que evidencia un entorno con niveles mínimos de contagio financiero a lo largo de todo el horizonte analizado.

## Conclusión

El análisis revela que la estructura de cointegración entre los mercados internacionales se mantuvo relativamente estable entre ambos periodos, e incluso aumentó ligeramente durante la pandemia. Sin embargo, este mayor nivel de interconexión no se tradujo en una intensificación del contagio financiero. Por el contrario, la evidencia empírica muestra que los choques de volatilidad prácticamente no se propagaron entre mercados, ni en la etapa de baja volatilidad previa a la pandemia ni en el entorno altamente incierto posterior a 2020.

El modelo Network GARCH demuestra que, aún cuando algunos mercados comparten relaciones de equilibrio de largo plazo, esto no implica necesariamente transmisión de volatilidad. Los coeficientes estimados sugieren que la influencia de los vecinos es mínima o inexistente, lo que permite concluir que la dinámica global estuvo caracterizada por niveles muy bajos de contagio financiero. De este modo, se rechaza la hipótesis de que un incremento

en la volatilidad global como el generado por la pandemia aumenta los efectos de contagio dentro de la red.

En síntesis, los mercados financieros analizados se comportaron de manera mayormente aislada, registrando una independencia notable frente a los choques de volatilidad de sus contrapartes.

## Referencias

Black, F. & Scholes, M. (1973), ‘The pricing of options and corporate liabilities’, *Journal of Political Economy* **81**(3), 637–654.

**URL:** <https://www.jstor.org/stable/1831029>

Carriello, B. B. (2005), ‘El contagio financiero en países emergentes’, *\*Pensamiento & Gestión\** **19**(34), 43–77.

**URL:** <https://www.redalyc.org/pdf/646/64601903.pdf>

Claessens, S. & Forbes, K. J. (2001), International financial contagion: An overview of the issues and the book, *in* S. Claessens & K. J. Forbes, eds, ‘\*International Financial Contagion\*’, Springer, Boston, MA, pp. 3–17.

Engle, R. F. (1982), ‘Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation’, *Econometrica* **50**(4), 987–1007.

**URL:** <https://doi.org/10.2307/1912773>

Engle, R. F. & Granger, C. W. J. (1987), ‘Co-integration and error correction: Representation, estimation, and testing’, *Econometrica* **55**(2), 251–276.

**URL:** <https://www.jstor.org/stable/1913236>

Forbes, K. J. & Rigobon, R. (2002), ‘No contagion, only interdependence: Measuring stock market comovements’, *Journal of Finance* **57**(5), 2223–2261.

**URL:** <https://www.jstor.org/stable/3094510>

Indices, S. D. J. (2025), ‘Vix — introducción’, <https://www.spglobal.com/spdji/es/vix-intro/>.

J.P. Morgan / Reuters (1996), *RiskMetrics<sup>TM</sup> — Technical Document (4th Edition)*, Morgan Guaranty Trust Company of New York and Reuters Ltd, New York.

**URL:** <https://www.msci.com/documents/10199/5915b101-4206-4ba0-ae2-3449d5c7e95a>

Markowitz, H. (1952), ‘Portfolio selection’, *The Journal of Finance* **7**(1), 77–91.

**URL:** <https://www.jstor.org/stable/2975974>

Monex (2024), ‘Las principales bolsas de valores del mundo y su impacto en los mercados financieros’, <https://blog.monex.com.mx/mercados-financieros/las-bolsas-de-valores-mas-famosas-del-mundo>.

Rodríguez Benavides, D. & Perrotini Hernández, I. (2021), ‘Las correlaciones dinámicas de contagio financiero: Estados unidos y américa latina’, *Revista Mexicana de Economía y Finanzas, Nueva Época* **14**(2), 1–25.

**URL:** <https://www.remef.org.mx/index.php/remef/article/view/316>

Rossi, G. D. (2013), ‘La volatilidad en mercados financieros y de commodities: un repaso de sus causas y la evidencia reciente’, *Invenio* **13**(1), 59–74.

**URL:** <https://www.redalyc.org/pdf/877/87726343005.pdf>

Sharpe, W. F. (1964), ‘Capital asset prices: A theory of market equilibrium under conditions

of risk', *The Journal of Finance* **19**(3), 425–442.

**URL:** <https://www.jstor.org/stable/2977928>

Zhou, J., Li, D., Pan, R. & Wang, H. (2020), 'Network garch model', *Statistica Sinica* **30**(4), 1723–1740.

**URL:** <https://www.jstor.org/stable/26969393>